

การจัดกลุ่มข้อมูลที่ไม่มีความสมดุลกันโดยใช้การเรียนรู้เชิง  
ลึกแบบผสม

Hybrid Deep Learning for Class Imbalance on  
Classification

ธนวัฒน์ หลอดแก้ว

Thanawat Lodkaew

59070071

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต  
สาขาวิชาเทคโนโลยีสารสนเทศ คณะเทคโนโลยีสารสนเทศ  
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง  
ภาคเรียนที่ 1 ปีการศึกษา 2562

การจัดกลุ่มข้อมูลที่ไม่มีความสมดุลกันโดยใช้การเรียนรู้เชิง  
ลึกแบบผสม

Hybrid Deep Learning for Class Imbalance on  
Classification

โดย

ธนวัฒน์ หลอดแก้ว  
รหัสประจำตัว 59070071

อาจารย์ที่ปรึกษา  
รองศาสตราจารย์ ดร. กิตีส์ุชาติ พสุภา

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรบัณฑิต  
สาขาวิชาเทคโนโลยีสารสนเทศ คณะเทคโนโลยีสารสนเทศ  
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง  
ภาคเรียนที่ 1 ปีการศึกษา 2562

# Hybrid Deep Learning for Class Imbalance on Classification

Thanawat Lodkaew

A PROJECT SUBMITTED IN PARTIAL FULFILLMENT  
OF THE REQUIREMENT FOR THE DEGREE OF  
BACHELOR OF SCIENCE PROGRAM IN INFORMATION TECHNOLOGY  
FACULTY OF INFORMATION TECHNOLOGY  
KING MONGKUT'S INSTITUTE OF TECHNOLOGY LADKRABANG

1/2019

**COPYRIGHT 2019**

**FACULTY OF INFORMATION TECHNOLOGY**

**KING MONGKUT'S INSTITUTE OF TECHNOLOGY LADKRABANG**

ใบรับรองปริญญาโท ประจำปีการศึกษา 2562  
คณะเทคโนโลยีสารสนเทศ  
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เรื่อง การจัดกลุ่มข้อมูลที่ไม่มีความสมดุลกันโดยใช้การเรียนรู้เชิงลึก  
แบบผสม

HYBRID DEEP LEARNING FOR CLASS  
IMBALANCE ON CLASSIFICATION

ผู้จัดทำ

1. ธนวัฒน์ หลอดแก้ว รหัสประจำตัว 59070071

รองศาสตราจารย์ ดร. กิตติ์สุชาติ พสุภา อาจารย์ที่ปรึกษา

(.....)

# ใบรับรองโครงการ (PROJECT)

## เรื่อง

การจัดกลุ่มข้อมูลที่ไม่มีความสมดุลกันโดยใช้การเรียนรู้เชิงลึกแบบผสม  
Hybrid Deep Learning for Class Imbalance on Classification

ธนวัฒน์ หลอดแก้ว รหัสประจำตัว 59070071

ขอรับรองว่ารายงานฉบับนี้ ข้าพเจ้าไม่ได้คัดลอกมาจากที่ได้  
รายงานฉบับนี้ได้รับการตรวจสอบและอนุมัติให้เป็นส่วนหนึ่งของ  
การศึกษาวิชาโครงการ หลักสูตรวิทยาศาสตรบัณฑิต (เทคโนโลยีสารสนเทศ)  
ภาคเรียนที่ 1 ปีการศึกษา 2562

.....  
ธนวัฒน์ หลอดแก้ว

ชื่อรายงาน	การจัดกลุ่มข้อมูลที่ไม่มีความสมดุลกันโดยใช้การเรียนรู้เชิงลึกแบบผสม
ชื่อนักศึกษา	ธนวัฒน์ หลอดแก้ว
รหัสนักศึกษา	59070071
สาขาวิชา	เทคโนโลยีสารสนเทศ
อาจารย์ที่ปรึกษา	รองศาสตราจารย์ ดร. กิต์สุชาติ พสุภา
ปีการศึกษา	2562

## บทคัดย่อ

บทคัดย่อ

<b>Project Title</b>	Hybrid Deep Learning for Class Imbalance on Classification
<b>Name</b>	Thanawat Lodkaew
<b>Student ID</b>	59070071
<b>Department</b>	Information Technology
<b>Advisor</b>	Assoc. Prof. Dr. Kitsucart Pasupa
<b>Year</b>	2019

## **Abstract**

Abstract eng



# กิตติกรรมประกาศ

แก้ไขกิตติกรรมประกาศในไฟล์ acknowledgement.tex

ธนวัฒน์ หลอดแก้ว

ผู้จัดทำรายงาน

วันที่ 10 พฤศจิกายน พ.ศ. 2561

# สารบัญ

	หน้า
บทคัดย่อ	i
บทคัดย่อ ภาษาอังกฤษ	ii
กิตติกรรมประกาศ	iii
สารบัญ	iv
สารบัญตาราง	v
สารบัญภาพ	vi
บทที่ 1 บทนำ	1
1.1 ที่มาและความสำคัญ	1
1.2 ความมุ่งหมายและวัตถุประสงค์ของการศึกษา	2
1.3 ขอบเขตการพัฒนาโครงการ	2
1.4 ขั้นตอนการดำเนินงาน	2
1.5 ประโยชน์ที่คาดว่าจะได้รับ	2
บทที่ 2 การทบทวนวรรณกรรมที่เกี่ยวข้อง	3
2.1 ทฤษฎีที่เกี่ยวข้อง	3
บทที่ 3 วิธีการดำเนินการวิจัย	5
3.1 ข้อสมมติฐาน	5
3.2 การทำการทดลอง	5
บทที่ 4 ผลการทดลองเบื้องต้นหรือระบบต้นแบบ	8
บทที่ 5 บทสรุป	9
บรรณานุกรม	10
ภาคผนวก ก เรื่องที่หนึ่ง	11

# สารบัญตาราง

หน้า

# สารบัญภาพ

	หน้า
รูปที่ 3.1 ภาพตัวอย่างของชุดข้อมูล CelebA	5
รูปที่ 3.2 ภาพตัวอย่างของชุดข้อมูล Cow	6
รูปที่ 3.3 ภาพตัวอย่างของชุดข้อมูล CIFAR-10	7

# บทที่ 1

## บทนำ

### 1.1 ที่มาและความสำคัญ

ในด้านการเรียนรู้ของเครื่องจักร (Machine Learning) ความไม่สมดุลกันของข้อมูล หมายถึง การที่จำนวนตัวอย่างของแต่ละกลุ่มข้อมูลมีจำนวนไม่เท่ากัน ซึ่งความไม่สมดุลกันของข้อมูลนี้ถูกนิยามให้เป็นปัญหาในการจัดกลุ่มข้อมูล (Classification) สาเหตุที่ความไม่สมดุลกันของข้อมูลเป็นปัญหา คือ อัลกอริทึมการจัดกลุ่ม (Classification Algorithm) จะทำงานได้อย่างมีประสิทธิภาพก็ต่อเมื่อจำนวนตัวอย่างของแต่ละกลุ่มข้อมูลมีจำนวนที่เท่าหรือใกล้เคียงกัน เมื่อมีความไม่สมดุลกันของข้อมูลจะทำให้การทำงานของอัลกอริทึมมีประสิทธิภาพด้อยลง ซึ่งอาจจะด้อยลงจนไม่สามารถจัดกลุ่มข้อมูลได้เลย

การจัดกลุ่มข้อมูลที่มีจำนวนตัวอย่างของแต่ละกลุ่มไม่สมดุลกันเป็นเรื่องธรรมดาอย่างมากในทางปฏิบัติ เนื่องจากข้อมูลที่เกิดขึ้นล้วนแต่ไม่สามารถคาดเดาได้อย่างแน่นอนว่าจำนวนตัวอย่างของแต่ละกลุ่มจะสมดุลกัน อีกทั้งข้อมูลส่วนใหญ่ยังมีลักษณะที่มีจำนวนตัวอย่างของแต่ละกลุ่มไม่สมดุลกัน เช่น ในระหว่างวันอยู่ในช่วงเป็นสัปดาห์ ช่วงเวลาที่วันแสดงพฤติกรรมเป็นสัปดาห์จะมีจำนวนน้อยกว่าช่วงเวลาที่วันไม่แสดงพฤติกรรมเป็นสัปดาห์ เป็นต้น ในด้านการเรียนรู้ของเครื่องจักร มีความเป็นไปได้ว่าตัวจัดกลุ่มข้อมูลที่ถูกสร้างขึ้นจากชุดข้อมูลที่มีจำนวนตัวอย่างของแต่ละกลุ่มไม่สมดุลกันจะมีความลำเอียงในการจัดกลุ่ม กล่าวคือ มีโอกาสสูงที่ตัวจัดกลุ่มจะระบุว่าข้อมูลเป็นกลุ่มส่วนมาก (Majority Class) มากกว่าเป็นกลุ่มส่วนน้อย (Minority Class) ซึ่งเป็นผลทำให้การระบุข้อมูลเป็นกลุ่มส่วนน้อยมีความแม่นยำที่ต่ำกว่ามาตรฐาน ซึ่งความแม่นยำในการระบุข้อมูลเป็นแต่ละกลุ่มควรจะเท่าหรือใกล้เคียงกัน

ที่ผ่านมาได้มีการศึกษาเกี่ยวกับปัญหาการจัดกลุ่มข้อมูลในลักษณะนี้อย่างกว้างขวาง และได้แสดงให้เห็นถึงความสำคัญของปัญหาของการจัดกลุ่มข้อมูลที่มีจำนวนตัวอย่างของแต่ละกลุ่มไม่สมดุลกัน ซึ่งทำให้ประสิทธิภาพการจัดกลุ่มข้อมูลมีความแม่นยำที่ต่ำ ดังนั้นปัญหานี้จำเป็นต้องถูกจัดการ [1] เพื่อที่จะแก้ปัญหการจัดกลุ่มข้อมูลที่มีจำนวนตัวอย่างของแต่ละกลุ่มไม่สมดุลกัน ได้มีเทคนิคเกิดขึ้นมากมาย โดยสามารถแบ่งเทคนิคการแก้ปัญหาได้ 2 ระดับ คือ (1) ระดับข้อมูล (Data-Level) ที่ซึ่งเป็นการแก้ปัญหาโดยการจัดการข้อมูลก่อนที่จะถูกนำไปประมวลผลในกระบวนการจัดกลุ่มข้อมูล โดยการสุ่มเพิ่มจำนวนตัวอย่างข้อมูล (Over-Sampling) และการสุ่มลดจำนวนตัวอย่างข้อมูล (Under-Sampling) เป็นเทคนิคในการแก้ปัญหาในระดับข้อมูล เทคนิคการแก้ปัญหาในระดับนี้เป็นการแก้ปัญหาแบบเบื้องต้นที่สามารถดำเนินการได้ง่าย อย่างไรก็ตามการสุ่มเพิ่มจำนวนตัวอย่างข้อมูลสามารถทำให้เกิดปัญหา Overfitting ตามมาได้อย่างง่ายดาย ในทางเดียวกันการสุ่มลดจำนวนตัวอย่างข้อมูลอาจจะเป็นการกำจัดสารสนเทศที่เป็นประโยชน์ต่อการจัดกลุ่มข้อมูลออกไป (2) ระดับตัวจัดกลุ่ม (Classifier-Level) ที่ซึ่งเป็นการแก้ปัญหาโดยการจัดการอัลกอริทึมการจัดกลุ่ม โดยการ thresholding การเรียนรู้แบบความเสียหายที่รู้สึกได้ง่าย (Cost-Sensitive Learning) การจัดกลุ่มข้อมูลแบบหนึ่งกลุ่ม (One-Class Classification) และการผนวกกันของหลายเทคนิค อย่างไรก็ตามเทคนิคเหล่านี้มียังไม่สามารถแก้ปัญหาได้อย่างมีประสิทธิภาพในทุก ๆ ชุดข้อมูล กล่าวคือ เทคนิคสามารถให้ความแม่นยำในการจัดกลุ่มข้อมูลแต่ละกลุ่มได้อย่างน่าพอใจสำหรับชุดข้อมูล A แต่ไม่สามารถทำได้มีประสิทธิภาพสำหรับชุด

ข้อมูล B เป็นต้น ดังนั้นเทคนิคใหม่ที่จะสามารถการแก้ปัญหาการจัดกลุ่มข้อมูลที่ไม่สมดุลกันได้อย่างมีประสิทธิภาพ และปรับเข้าได้กับทุกชุดข้อมูลจำเป็นต้องถูกคิดค้นขึ้น

## 1.2 ความมุ่งหมายและวัตถุประสงค์ของการศึกษา

1. เพื่อศึกษาการจัดการปัญหาความไม่สมดุลกันของข้อมูลด้วยเทคนิคต่าง ๆ
2. เพื่อศึกษาและเข้าในการทำงานของการเรียนรู้เชิงลึก (Deep Learning) อย่างทอ่งแท้
3. เพื่อที่จะดัดแปลงแบบจำลองให้สามารถแก้ปัญหาความไม่สมดุลกันของข้อมูลได้
4. เพื่อคิดค้นเทคนิคการเรียนรู้เชิงลึกแบบผสมที่สามารถจัดกลุ่มของข้อมูลได้อย่างมีประสิทธิภาพ
5. เพื่อศึกษาความเป็นไปได้ในการประยุกต์ใช้เทคนิคที่คิดค้นกับชุดข้อมูลที่แตกต่างกัน

## 1.3 ขอบเขตการพัฒนาโครงการ

1. ดัดแปลงแบบจำลองการเรียนรู้เชิงลึกให้สามารถจัดกลุ่มข้อมูลโดยไม่มีความลำเอียงกับกลุ่มส่วนมาก
2. เปรียบเทียบประสิทธิภาพเชิงความแม่นยำของแบบจำลองที่ดัดแปลงกับเทคนิคอื่น ๆ ที่ใช้ในการแก้ปัญหาความไม่สมดุลกันของข้อมูล

## 1.4 ขั้นตอนการดำเนินงาน

1. ศึกษารูปแบบการแก้ปัญหาการจัดกลุ่มข้อมูลที่ไม่มีความสมดุล
2. ศึกษาการทำงานของแบบจำลองการเรียนรู้เชิงลึก
3. ศึกษางานวิจัยที่เกี่ยวข้อง
4. ตั้งข้อสมมติฐาน
5. ออกแบบแนวทางการสร้างแบบจำลองการเรียนรู้เชิงลึกแบบผสม
6. สร้างแบบจำลองการเรียนรู้เชิงลึกแบบผสมตามที่ออกแบบ
7. กำหนดจุดประสงค์การทดลองแต่ละแบบ
8. ดำเนินการทำการทดลอง
9. สรุปผลการทดลอง

## 1.5 ประโยชน์ที่คาดว่าจะได้รับ

1. แบบจำลองการจัดกลุ่มข้อมูลสามารถให้ความแม่นยำที่สูงในการระบุข้อมูลแต่ละกลุ่ม แม้ว่าจะมีความไม่สมดุลกันของข้อมูล

## บทที่ 2

# การทบทวนวรรณกรรมที่เกี่ยวข้อง

### 2.1 ทฤษฎีที่เกี่ยวข้อง

#### 2.1.1 การเรียนรู้เชิงลึก (Deep Learning)

#### 2.1.2 การเรียนรู้เชิงลึกแบบผสม (Hybrid Deep Learning)

ไม่มีนิยามที่แน่นอนสำหรับแบบจำลองการเรียนรู้เชิงลึกแบบผสมว่าเป็นแบบจำลองที่มีลักษณะอย่างไร จากการศึกษาค้นพบว่า แบบจำลองที่เกิดจากการผสมผสานกันของแบบจำลองการเรียนรู้เชิงลึกหลายสถาปัตยกรรม หรือแม้กระทั่งแบบจำลองที่มีการการคิดค้น หรือดัดแปลงฟังก์ชันสูญเสีย (Loss Function) เพื่อใช้ในการเรียนรู้ ก็สามารถเรียกได้ว่าเป็นแบบจำลองการเรียนรู้เชิงลึกแบบผสม เมื่อไม่นานมานี้ได้มีงานวิจัยพยายามคิดค้นแบบจำลองการเรียนรู้เชิงลึกแบบผสมมาเพื่อแก้ไขปัญหาต่าง ๆ และได้แสดงให้เห็นว่าแบบจำลองการเรียนรู้เชิงลึกแบบผสมนั้นมีลักษณะที่หลากหลาย Haixia Long et al. [2] ได้นำเสนอสถาปัตยกรรมการเรียนรู้เชิงลึกแบบผสมสำหรับการระบุไฮดรอกซีโพรลีน (Hydroxyproline) และไฮดรอกซีไลซีน (Hydroxylysine) ในโปรตีน โดยการนำโครงข่ายประสาทแบบคอนโวลูชัน (Convolutional Neural Network: CNN) มาผนวกกับโครงข่ายประสาทแบบลองชอร์ตเทอมเมมโมรี่ (Long Short-Term Memory: LSTM) ที่ซึ่ง CNN ถูกใช้ในการสกัดคุณลักษณะของปฏิกิริยาของกรดอะมิโน และ LSTM ถูกใช้ในการสกัดการคงอยู่ของความสัมพันธ์กันระหว่างกรดอะมิโน ผลการทดลองแสดงให้เห็นว่าสถาปัตยกรรมการเรียนรู้เชิงลึกแบบผสมนี้สามารถปรับปรุงประสิทธิภาพของแบบจำลองได้ Y. Sun et al. [3] ได้ใช้แบบจำลอง CNN หลายตัวในการสกัดคุณลักษณะสำหรับการยืนยันตัวตนด้วยใบหน้า ซึ่งคุณลักษณะของแต่ละพื้นที่ของใบหน้าจะถูกสกัดด้วยแบบจำลอง CNN ที่ต่างกัน และคุณลักษณะของแต่ละพื้นที่จะถูกนำมารวมกันเพื่อจัดกลุ่ม และยืนยันตัวตนด้วยเครื่องจักรโบลทซ์มันน์แบบจำกัด (Restricted Boltzmann Machine: RBM) Jin-Young Kim et al. [4] ได้คิดค้นการผสมผสานกันระหว่างโครงข่ายการสร้างข้อมูลแบบควบคุมความจริงที่แอบแฝง (Latent Semantic Controlling Generative Adversarial Network: LSC-GAN) กับตัวเข้ารหัสอัตโนมัติแบบแปรเอนชัน (Variational Autoencoder: VAE) ที่ซึ่ง LSC-GAN ถูกใช้ในการสร้างข้อมูลมัลแวร์โดยอ้างอิงการแจกแจงปกติ (Gaussian Distribution) ของข้อมูลมัลแวร์จริง โดยข้อมูลจริงจะถูกนำไปแปลงให้อยู่ในรูปแบบแอบแฝง (Latent Space) ด้วย VAE เพื่อการสกัดคุณลักษณะและถูกนำไปใช้ต่อโดย LSC-GAN

งานวิจัยดังกล่าวข้างต้นแสดงให้เห็นว่าแบบจำลองการเรียนรู้เชิงลึกแบบผสมนั้นมีความหลากหลาย และมีประสิทธิภาพที่ดีกว่าแบบจำลองธรรมดา ดังนั้น ผู้จัดทำจึงเกิดความคิดที่จะคิดค้นแบบจำลองการเรียนรู้เชิงลึกแบบผสมมาเพื่อแก้ปัญหการจัดกลุ่มข้อมูลที่ไม่มีความสมดุล

#### 2.1.3 งานวิจัยที่เกี่ยวข้อง

เมื่อเทคนิคการจัดกลุ่มข้อมูลที่ประกอบด้วยโครงข่ายประสาทแบบคอนโวลูชันถูกใช้กับชุดข้อมูลที่มีความไม่สมดุลกัน อัตราการพยากรณ์ผิดพลาดจะมีค่าสูงเมื่อเทียบกับการเพิ่มขึ้นของจำนวนรอบของการเรียนรู้ของแบบจำลอง กล่าวคือ ยิ่งจำนวนรอบของการเรียนรู้สูงขึ้น จะทำให้อัตราการพยากรณ์ผิดพลาดสูงขึ้นด้วย [5] เบื้องหลังของสาเหตุที่ทำให้เป็นเช่นนั้น คือ ในเสตจ

ของการเรียนรู้ของแบบจำลองการเรียนรู้เชิงลึก ข้อมูลจะถูกแบ่งออกเป็นกลุ่ม ๆ ซึ่งทำให้แต่ละกลุ่มมีความไม่เท่าเทียมกันเมื่อข้อมูลไม่สมดุลกัน อีกทั้งบางกลุ่มอาจจะมีแค่ตัวอย่างของกลุ่มข้อมูลที่เป็นส่วนมาก หรือกลุ่มข้อมูลที่เป็นส่วนน้อยเท่านั้น เมื่อแบบจำลองได้เรียนรู้ข้อมูลจากกลุ่มเหล่านั้นในทุก ๆ รอบ จึงทำให้เกิดอัตราการพยากรณ์ผิดพลาดที่สูง

เมื่อไม่นานมานี้ได้มีงานวิจัยที่พยายามจัดการกับปัญหาการเรียนรู้ของแบบจำลองการเรียนรู้เชิงลึกเมื่อต้องเรียนรู้ข้อมูลที่มีความไม่สมดุลกัน ดังต่อไปนี้

- S. Wang et al. [6] ได้ทำการดัดแปลงฟังก์ชันสูญเสียอย่าง ค่าเฉลี่ยของกำลังสองของความคลาดเคลื่อน (Mean Square Error: MSE) เพื่อให้การเรียนรู้ของแบบจำลองการเรียนรู้เชิงลึกไม่มีความลำเอียงในการจดจำข้อมูลที่เป็นกลุ่มส่วนมากเกินไป โดยฟังก์ชันสูญเสียใหม่นี้มีชื่อว่า ค่าเฉลี่ยของความคลาดเคลื่อนของความผิดพลาด (Mean False Error: MFE) แต่ประสิทธิภาพของฟังก์ชันสูญเสียนี้อย่างไรก็ตามฟังก์ชันสูญเสียดังกล่าวยังไม่สามารถประยุกต์ใช้ได้กับ โครงข่ายความเชื่อแบบลึก (Deep Belief Network) และโครงข่ายประสาทแบบคอนโวลูชัน



## บทที่ 3

### วิธีการดำเนินการวิจัย

#### 3.1 ข้อสมมติฐาน

สมมติฐานของงานวิจัยนี้ คือ แบบจำลองการเรียนรู้เชิงลึกที่นำเสนอจะสามารถจัดการปัญหาความไม่สมดุลกันของข้อมูลได้อย่างมีประสิทธิภาพ

#### 3.2 การทำการทดลอง

##### 3.2.1 ชุดข้อมูล

เพื่อที่จะได้ผลการทดลองที่สามารถเปรียบเทียบประสิทธิภาพของเทคนิคการแก้ปัญหา จำเป็นจะต้องใช้ชุดข้อมูลที่หลากหลาย โดยแบ่งออกเป็นชุดข้อมูลที่มีความสมดุลและไม่สมดุลกันของข้อมูล ดังนี้

- CelebFaces Attributes Dataset (CelebA) [7] ชุดข้อมูลนี้มีความไม่สมดุลกันของข้อมูล ที่ซึ่งเป็นชุดข้อมูลขนาดใหญ่ที่ประกอบไปด้วยภาพหน้าของคนมีชื่อเสียงกว่า 1 หมื่นคน และมีจำนวนภาพมากกว่า 2 แสนภาพ โดยภาพจะมีลักษณะเป็นท่าทางของหน้าและพื้นหลังที่หลากหลายดังรูปที่ 3.1 CelebA นั้นมีคำอธิบายประกอบ (Annotation) ที่หลากหลายมาก เช่น คำอธิบายประกอบที่บอกว่าคนในภาพคือใคร และกำลังยิ้มอยู่หรือไม่ เป็นต้น



รูปที่ 3.1: ภาพตัวอย่างของชุดข้อมูล CelebA


- Cow [8] ชุดข้อมูลนี้มีความไม่สมดุลกันของข้อมูล ที่ซึ่งเป็นชุดข้อมูลประเภทวิดีโอ ที่ซึ่งแสดงการเป็นอยู่ของวัวในคอก โดยชุดข้อมูลถูกเก็บจากคอกวัวภายในฟาร์มโชคชัยด้วยกล้องวิดีโอ วิดีโอได้ถูกนำมาแปลงเป็นภาพเฟรม โดยภาพจะมีลักษณะเป็นภาพที่ถ่ายจาก

มูมบงดังรูปที่ 3.2 คำอธิบายประกอบสำหรับชุดข้อมูลนี้ คือ การแสดงพฤติกรรมเป็นสัตว์ของวัวแต่ละตัวในแต่ละเฟรม เช่น ในเฟรมที่ 5 วัว A แสดงพฤติกรรมเป็นสัตว์ วัว B ไม่แสดงพฤติกรรมเป็นสัตว์ และวัว C แสดงพฤติกรรมเป็นสัตว์ เป็นต้น โดยจำนวนเฟรมที่วัวแต่ละตัวไม่แสดงพฤติกรรมเป็นสัตว์มีจำนวนมากกว่าที่แสดงพฤติกรรมเป็นสัตว์



รูปที่ 3.2: ภาพตัวอย่างของชุดข้อมูล Cow

- CIFAR-10 [9] ชุดข้อมูลนี้มีความสมดุลกันของข้อมูล ที่ซึ่งเป็นชุดข้อมูลที่ประกอบไปด้วยภาพของสัตว์และยานพาหนะดังรูปที่ 3.3 โดยแบ่งออกเป็นยานพาหนะ 4 ประเภท คือ เครื่องบิน รถยนต์ เรือ และรถบรรทุก และสัตว์ 6 ประเภท คือ นก แมว กวาง หมา กบ และม้า ซึ่งแต่ละประเภทมีจำนวน 6,000 ภาพเท่ากัน รวมทั้งหมดเป็น 6 หมื่นภาพ คำอธิบายประกอบของชุดข้อมูลนี้ คือ ประเภทของภาพ



รูปที่ 3.3: ภาพตัวอย่างของชุดข้อมูล CIFAR-10

บทที่ 4  
ผลการทดลองเบื้องต้นหรือระบบต้นแบบ

บทที่สี่

## บทที่ 5

### บทสรุป

บทที่ห้า

## บรรณานุกรม

- [1] M. Buda, A. Maki, and M. A. Mazurowski, “A systematic study of the class imbalance problem in convolutional neural networks,” *CoRR*, vol. abs/1710.05381, 2017. [Online]. Available: <http://arxiv.org/abs/1710.05381>
- [2] H. Long, B. Liao, X. Xu, and J. Yang, “A hybrid deep learning model for predicting protein hydroxylation sites,” *International Journal of Molecular Sciences*, vol. 19, p. 2817, 09 2018.
- [3] Y. Sun, X. Wang, and X. Tang, “Hybrid deep learning for face verification,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, no. 10, pp. 1997–2009, Oct 2016.
- [4] J.-Y. Kim and S.-B. Cho, *Detecting Intrusive Malware with a Hybrid Generative Deep Learning Model: 19th International Conference, Madrid, Spain, November 21–23, 2018, Proceedings, Part I*, 11 2018, pp. 499–507.
- [5] Y. Yan, M. Chen, M. Shyu, and S. Chen, “Deep learning for imbalanced multimedia data classification,” in *2015 IEEE International Symposium on Multimedia (ISM)*, Dec 2015, pp. 483–488.
- [6] S. Wang, W. Liu, J. Wu, L. Cao, Q. Meng, and P. J. Kennedy, “Training deep neural networks on imbalanced data sets,” in *2016 International Joint Conference on Neural Networks (IJCNN)*, July 2016, pp. 4368–4374.
- [7] Z. Liu, P. Luo, X. Wang, and X. Tang, “Deep learning face attributes in the wild,” *CoRR*, vol. abs/1411.7766, 2014. [Online]. Available: <http://arxiv.org/abs/1411.7766>
- [8] K. Pasupa, N. Pantuwong, and S. Nopparit, “A comparative study of automatic dairy cow detection using image processing techniques,” *Artificial Life and Robotics*, vol. 20, no. 4, pp. 320–326, 2015.
- [9] A. Krizhevsky, V. Nair, and G. Hinton, “Cifar-10 (canadian institute for advanced research).” [Online]. Available: <http://www.cs.toronto.edu/~kriz/cifar.html>

ภาคผนวก ก  
เรื่องที่หนึ่ง